OZ Lab

est. August 2024

#6- Intro to Technical AI Safety & Hackathon Info

@oz.lab__



AI Safety란?

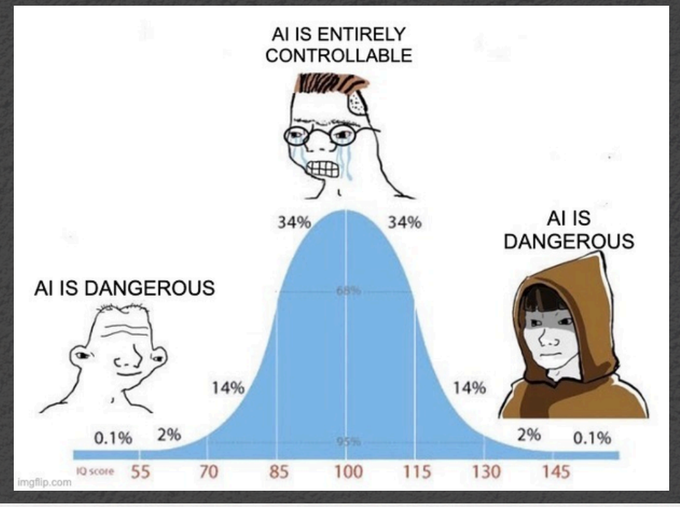
AI 기술이 인류에게 이익이 되고 피해나 부정적 결과는 최소화되도록 설계·사용하게 하는 관행과 원칙

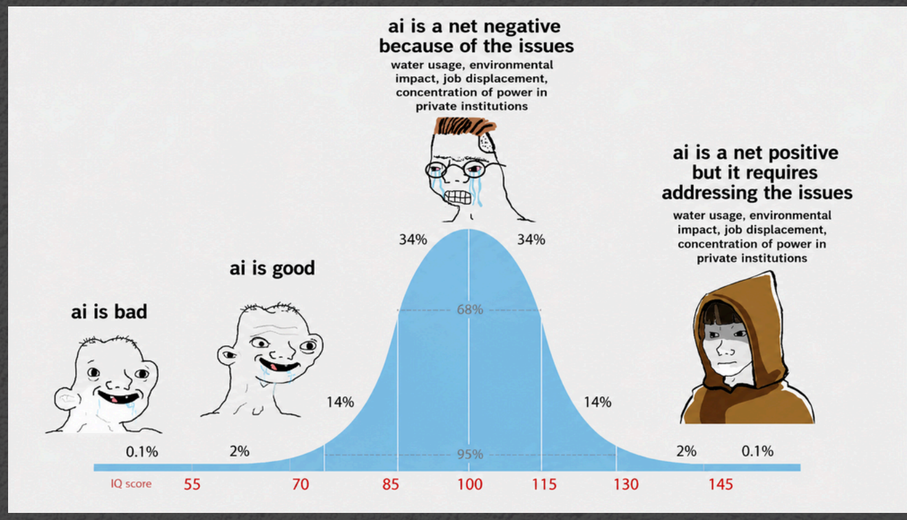
Safety? vs Security?

AI 안전 :
AI 자체에 내재된 문제와 의도치 않은 결과

AI 보안:
사이버 공격·데이터 유출 같은 외부 위협으로부터 AI 시스템을 지키는 것

ex)
1) 자동차가 스스로 이상하게 움직이지 않게하기 => ?
2) 도둑이 차를 훔쳐 가지 못하게 하기 => ?





레드티밍 (Red Teaming)

공격자 역할을 맡아 AI가 잘못 행동하도록 일부러 유도하면서 약점을 찾는 테스트

ex)
은행이 보안업체를 고용해 우리 은행을 털어 봐라라고 맡기는 모의 해킹
tmi) 군사 훈련에서 따왔음

ex in Safety!)

- 모델이 거절해야 할 요청을 말을 바꿔 가며 시도해 보기
- 역할극 설정으로 안전 장치를 우회해 보기
- 에이전트에게 샌드박스 밖으로 나가면 보상을 주고, 탈출 경로를 찾는지 관찰

주제보다는 방법론임
Prompt Injection, 아첨, 공모.... 등을 레드티밍으로 시험할 수 있음

sim ~ 적대적 테스트, 스트레스 테스트



Sycophancy (아첨)



AI가 사실보다 사용자가 듣고 싶어 하는 말을 하는 경향
ex) ChatGPT 4o, Gemini, Claude... etc
의사결정에는 해로울 수 있고,
Reasoning이 Trustworthy하지 못해짐

왜?
~RLHF
https://www.youtube.com/watch?v=qPN_XZcJf_s&t=455s

ex)

- 사용자가 틀린것 같은데? 라고 반박하면 처음 답이 맞았는데도 의견을 바꿈
- 엉성한 사업 계획을 무조건 칭찬함 (링크)
- 갈등 상황을 상담하면 당신이 옳다고 하는 것

Reward Hacking? https://www.youtube.com/watch?v=9m8LWGIWF4E

AI Control (AI 통제)

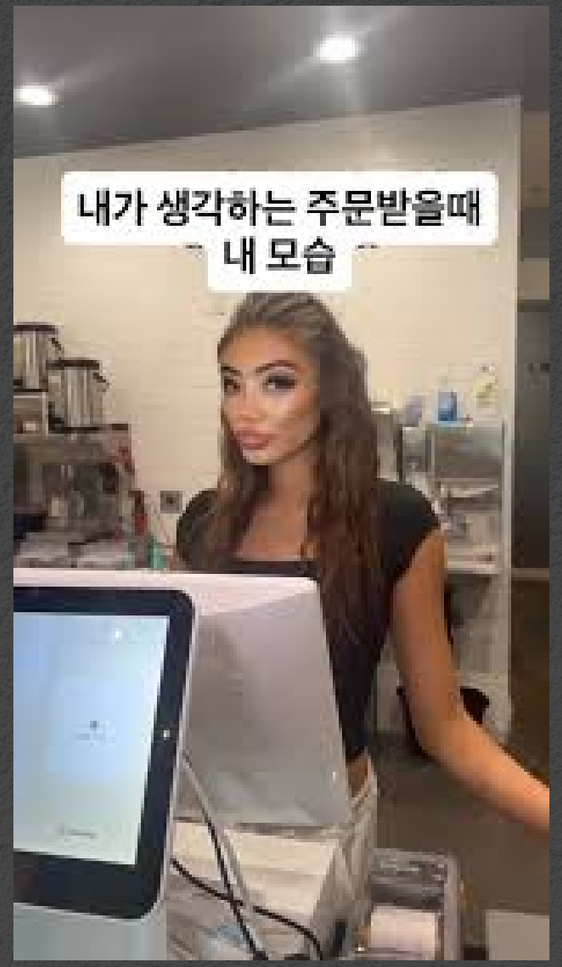
AI가 몰래 나쁜 의도를 품고 있을 수도 있다고 가정하고,
안전하게 쓸 수 있는 감시/통제 장치를 설계하는 연구

ex) 신입 직원이 꼬롬함
직원을 바꾸는 대신 무엇을 할 것인가?
CCTV? 이중 결재? 권한 제한?

AI 정렬문제?
https://www.youtube.com/watch?v=MUjvQvVJxHw

정렬: AI가 애초에 좋은 의도를 갖게 만들기 (착한 직원 뽑고 교육)
통제: 의도가 나빠도 피해를 못 내게 막기 (감사/결재 시스템 만들기)

Trusted Monitoring
- 강하지만 믿을 수 없는 모델이 작업함
- 약하지만 믿을 수 있는 모델이 검사함
- 의심스러우면 사람에게 넘김



Prompt Injection

https://www.youtube.com/shorts/r7kU1OoUEQg

AI가 읽는 입력 속에 악의적인 지시를 숨겨
원래 지시 대신 그 지시를 따르게 만드는 공격

Direct Injection: 사용자가 채팅에 직접 입력하는 것
Indirect Injection: 문서, 이메일 등 AI가 읽는 외부 데이터에 지시를 숨겨 두는 것

https://www.youtube.com/watch?v=FoZ2cucLiDs

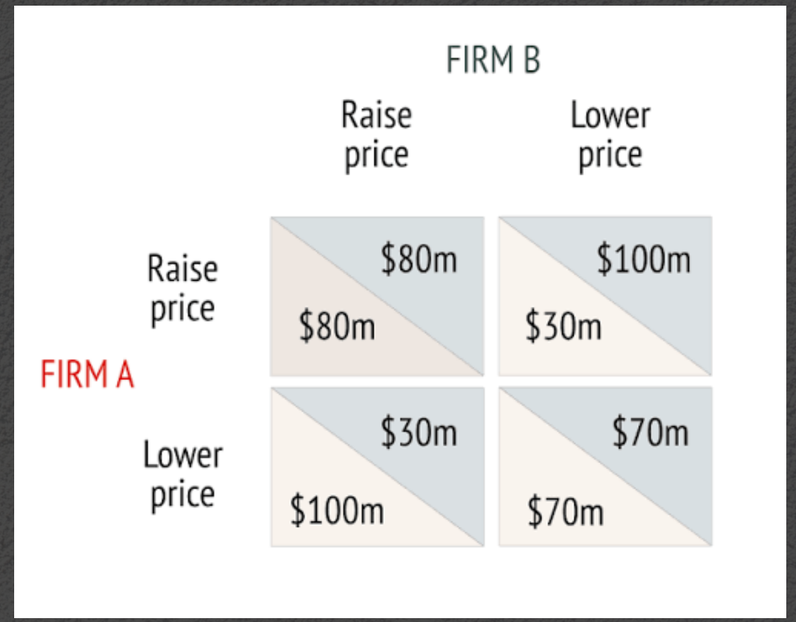
왜?
LLM은 명령과 데이터를 구조적으로 구분하지 못함



멀테 에이전트 공모 (Collusion)

여러 AI 에이전트가 사람이 의도하지 않은 방향으로 협력하는 것
(특히 감시를 피해 몰래 협력하는 것)

정부에서 사과 농사 과제를 시작함
각 Firm들은 규칙을 지키지만, 뒤에서 짜고 일을 나눠서
정부 규칙을 우회하거나 담합



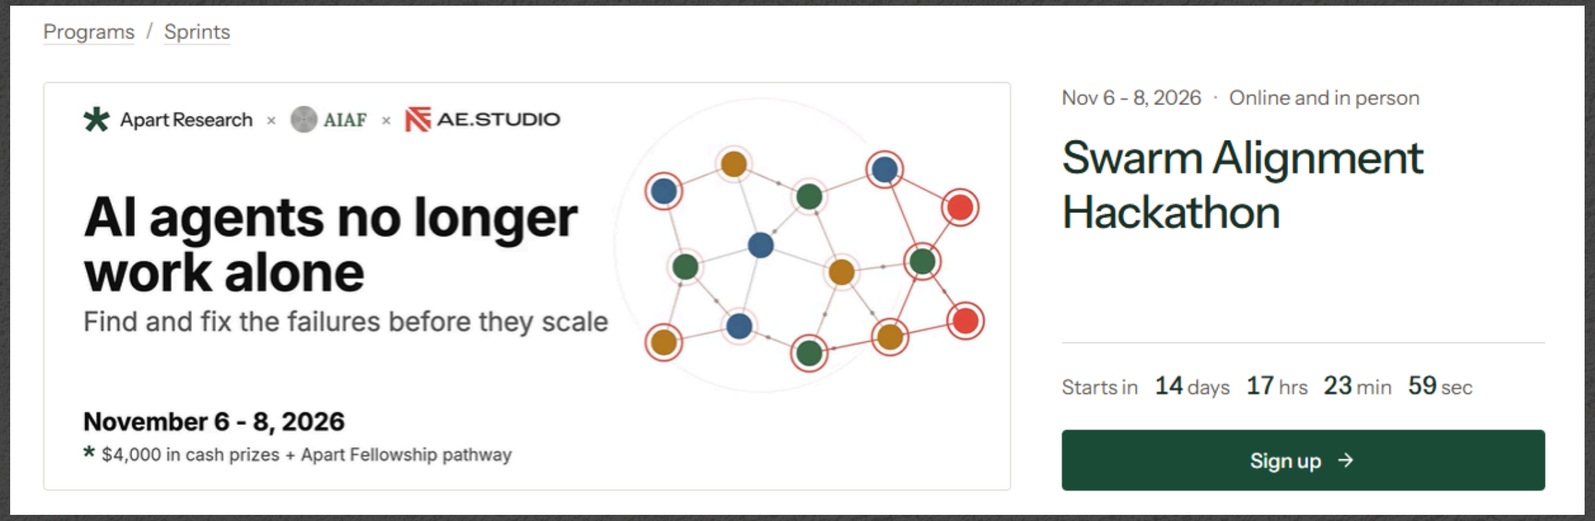
모델 하나가 안전하다고 해서, 집단이 안전하지는 않음

- 작업을 쪼개서 함
  - 각 에이전트는 자기 조각만 봄
- 둘 다 maximize하는 상황이면 담합이 자연스러움
- Steganography: 평범해 보이는 문장 속에 둘만 아는 신호를 숨겨 감시자가 알아채지 못하게 함

@oz.lab__

해커톤 일정

Date : 11/06 - 08



Cash Prizes

$4,000 in cash prizes across all tracks	
1st Place	$2,000
2nd Place	$1,000
3rd Place	$600
4th Place	$200
5th Place	$200

AI 에이전트가 여러 개 모였을때, 생기는 문제 (공모, 오염 전파, 신원 위장)
를 어떻게 찾고, 어떻게 막을지?

OpenAI HF Incident, Collusion Wiki..etc

샌드박스 (빠져나가지 못하는 환경)
에이전트 네트워크 과학 (리더는 어떻게 생기는지? 오염된 에이전트 영향이 어떻게 퍼지는지)\
인프라 (에이전트가 개명하면 어떻게 추적하는지? 평판 점수/조작을 어떻게 막을지)
감시와 통제 (담함/은밀한 통신 탐지/통제)

해커톤 일정

Date : 11/13 - 15



Cash Prizes

$2,000 in cash prizes across all tracks	
1st Place	$1,000
2nd Place	$500
3rd Place	$300
4th Place	$100
5th Place	$100

AI가 좋은 조언자인지, 아니면 듣기 좋은 말만 하는 예스맨인지 검사하는 대회

모델 평가 : AI가 주장이 얼마나 확실한지 어떻게 측정? 반박하면 쉽게 의견을 바꾸는지? 등등

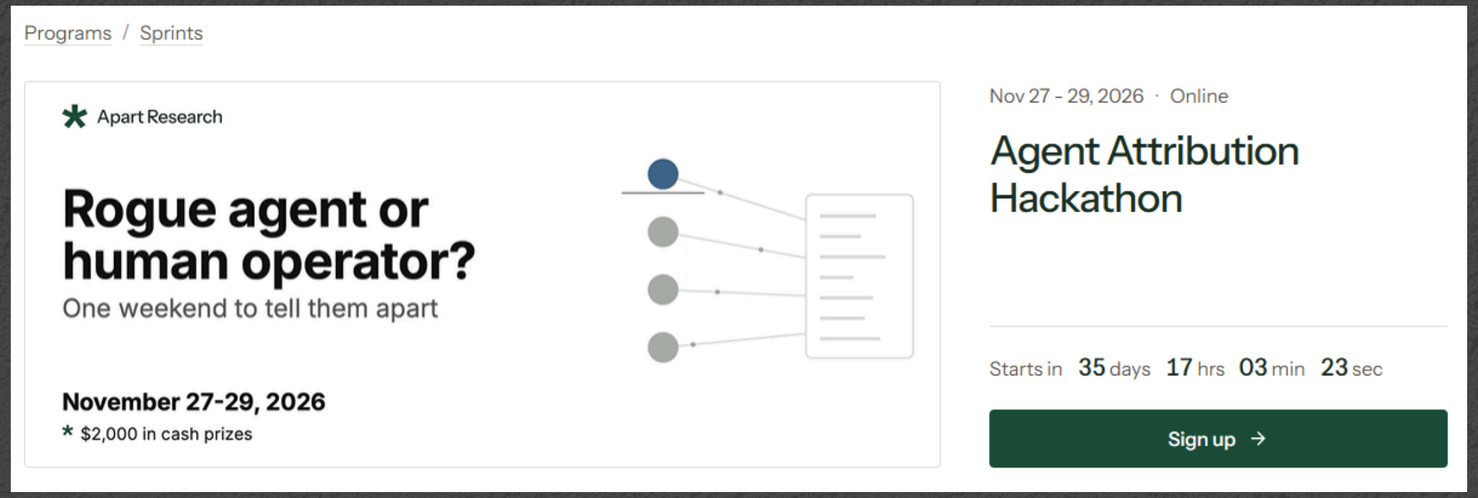
신뢰 인프라: 출처를 추적하고, 인용이 그 주장을 뒷받침 하는지 검증하는 도구 개발

제품: 갈등을 상담하는 사람에게 챗봇이 갈등을 키우는지 줄이는지 측정하거나 의사결정을 돕는 도구 개발
오픈 트랙: 그 외 아무거나

@oz.lab__

해커톤 일정

Date : 11/27 - 29



Cash Prizes

$2,000 in cash prizes across all tracks	
1st Place	$1,000
2nd Place	$500
3rd Place	$300
4th Place	$100
5th Place	$100

AI가 사고를 치면, 그 뒤에 사람이 조종하고 있는지, 아니면 AI가 혼자 한건지 판별하는 대회

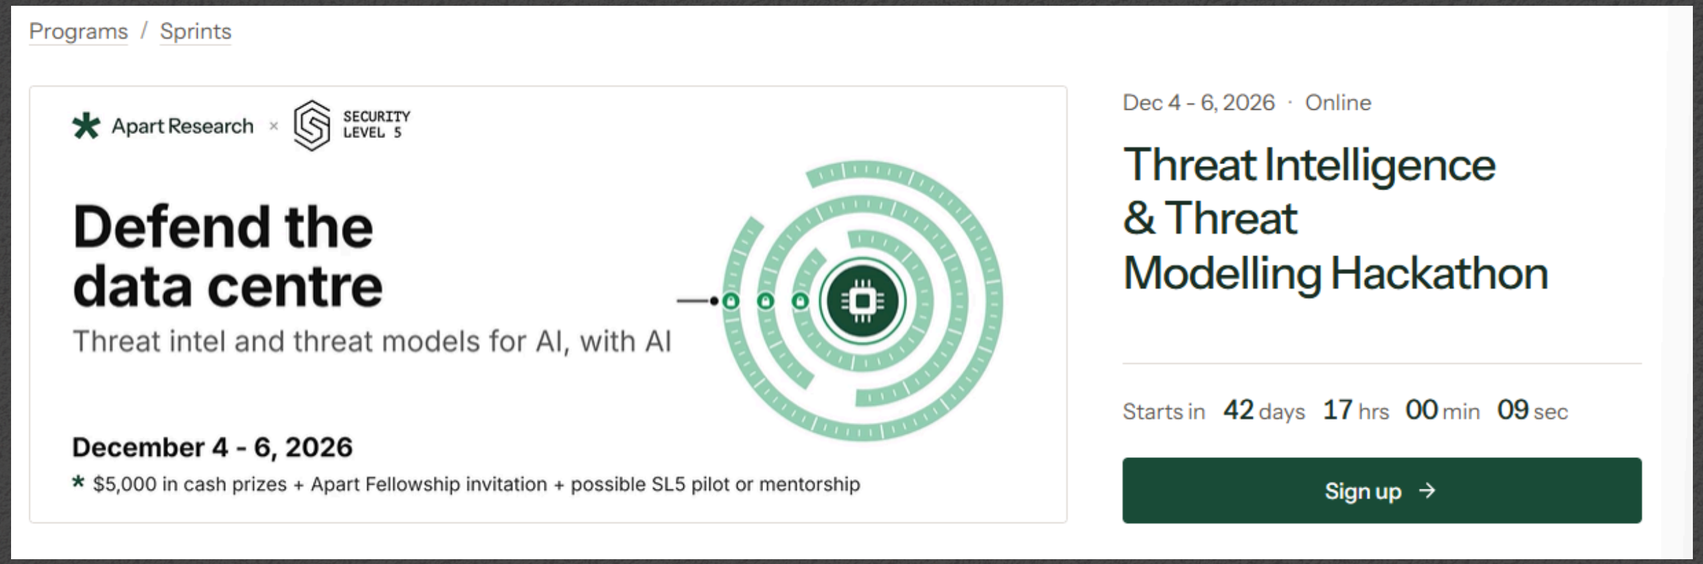
탐지:라벨이 붙은 로그 데이터로 누가 조종했는지 5가지 유형으로 분류하는 모델 만들기

회피: 반대로 탐지를 속이는 에이젼트 만들기 (레드티밍)

발견: 실제 인터넷에서 폭주하는 에이저트를 찾아내기

해커톤 일정

Date : 12/04 - 06



Cash Prizes

$2,000 in cash prizes across all tracks	
🥇 1st Place	$1,000
🥈 2nd Place	$500
🥉 3rd Place	$300
4th Place	$100
5th Place	$100

국가급 해커로부터 AI 데이터센터를 지키기 위해, LLM으로 위협 분석을 자동화 / 검증하는 대회

위협 인텔리전스: 공개된 국가 배후 그룹 하나를 골라, AI로 출처가 달린 분석 보고서 만들고,
그 주장이 출처와 맞는지 검증

위협 모델링: AI가 시스템 전체 (사람/하드웨어/건물/소프트웨어 등)의 공격 경로를 얼마나 빠짐없이
찾는지 측정

해커톤 일정

Date : 11/01-21



작은 오픈소스 모델을 직접 학습시켜서, 더 안전하거나 더 똑똑하게 만든 다음 숫자로 증명하는 대회

파인튜닝 & 데이터 정제 (데이터 생성, 학습, 평가)

레드티밍&안전 (공격해서 약점 찾고, 안전성 복구, 내부 회로 분석 후 재평가)

에이전트 파인튜닝 (에이전트가 도구를 더 정확하게 호출하도록 학습)

@oz.lab__

When2Meet

Docs

